Arquiteturas Agentic RAG Avançadas

Como o Model Context Protocol Está Revolucionando o Acesso a Dados e a Integração em Sistemas de IA

Alex Salgado Developer Advocate @ Elastic







Alex Salgado
Senior Developer Advocate
LATAM



@alexsalgadoprof

/in/alex-salgado/

- Mestre em Ciência da Computação pela UFF (Games)
- MBA UFF
- PhD Candidate UFF: Robótica/Visão Computacional

- + 25 anos de experiência na área de desenvolvimento de software
- Ocupei diversos cargos, trabalhando em startups, pequenas e grandes empresas como Oracle, CSN, BRQ/IBM, Chemtech/Siemens (9 anos).
- **8 anos** como professor universitário

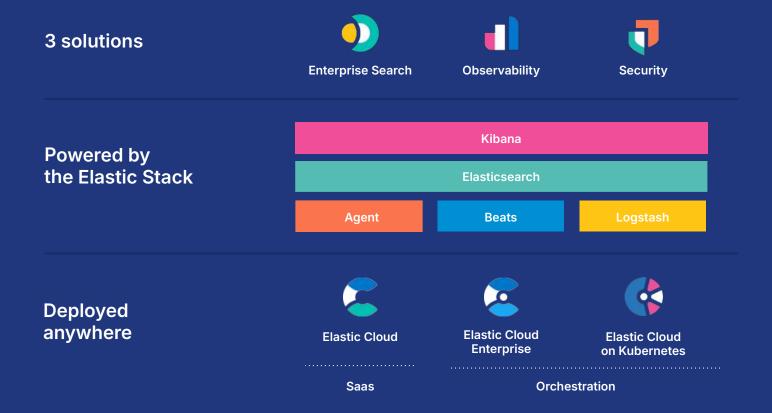








Three solutions powered by one stack





The Power of Elasticsearch + LLMs

Imagine asking complex questions about your data in English, Portuguese or Chinese using natural language and taking time to reason

1 Natural Language (MCP)

At what time of day did I take the most steps exploring Las Vegas yesterday?

2 Elasticsearch Query

```
GET apple-health-steps/_search { "size": 0, "query": { "bool": {
   "must": [ { "match": { "location": "Las Vegas, NV" } }, { "range": {
   "day": { "gte": "2025-05-13", "lte": "2025-05-13" } } } } } } }, "aggs":
   { "steps_by_hour": { "terms": { "field": "hour", "size": 24, "order": {
   "total_steps": "desc" } }, "aggs": { "total_steps": { "sum": { "field":
   "value" } } } }
}
```

3 SQL (Equivalent)

SELECT hour, SUM(value) as total_steps FROM apple_health_steps WHERE location = 'Las Vegas, NV' AND day = '2025-05-13' GROUP BY hour ORDER BY total_steps DESC LIMIT 1;

Da Geração de Texto à Tomada de Decisão

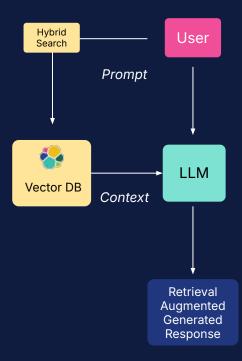
Prompting an LLM

Prompt the LLM and get a response. No other tools or components needed.



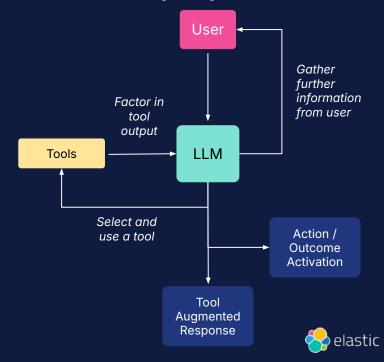
Retrieval Augmented Generation

Add a knowledge base to enhance accuracy and add novel information to the LLM



Agentic Flow

Decision Making enabled. LLM can prompt user for information, choose to use tools, interact with other agents, and affect the real world (ie. Triggering alerts, sending messages, etc...)



A Evolução da Busca

Busca 1.0

1970-2020

SQL, NoSQL Queries rígidas Só para DBAs Busca 2.0

2020-2024

RAG + Embeddings Vector Stores Ainda limitado Busca 3.0

2024+

RAG Agêntico

MCP + LLMs

Conversas naturais

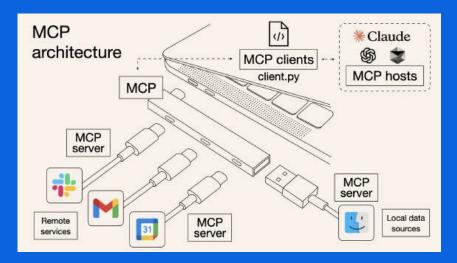
De queries complexas para conversas simples



O que é MCP

Model Context Protocol

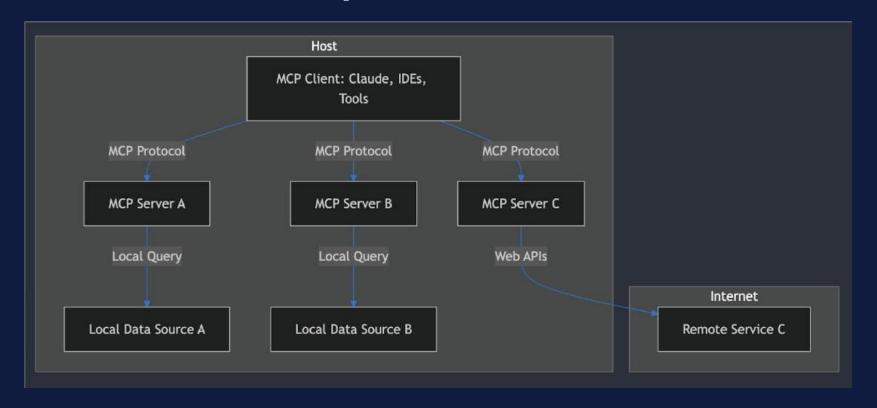
- Forma padronizada de LLMs acessarem ferramentas
- Criado pela Anthropic para resolver o compartilhamento de contexto
- Três primitivos principais: Recursos,
 Ferramentas e Prompts
- Pense nisso como uma API especificamente para ferramentas de LLM



Anthropic defines it as the USB-C port equivalent for agentic systems



Arquitetura MCP





Duas Abordagens para MCP + Elastic Personalizada

- Propósito geral *
- Configuração fácil
- Customização limitada



Customizada





Desafio: **Converse com sua saúde**

Pergunta 1:

"Quantos passos eu dei ontem?"

Question 2:

"Quantas voltas ao redor do maracanã eu teria completado se eu caminhasse o mesmo número de passos que dei **ontem?**"



Construindo um servidor MCP
personalizado que conecta o Claude Al
Desktop aos meus dados de fitness











RAG Agêntico: A Inteligência da Busca 3.0

RAG Tradicional

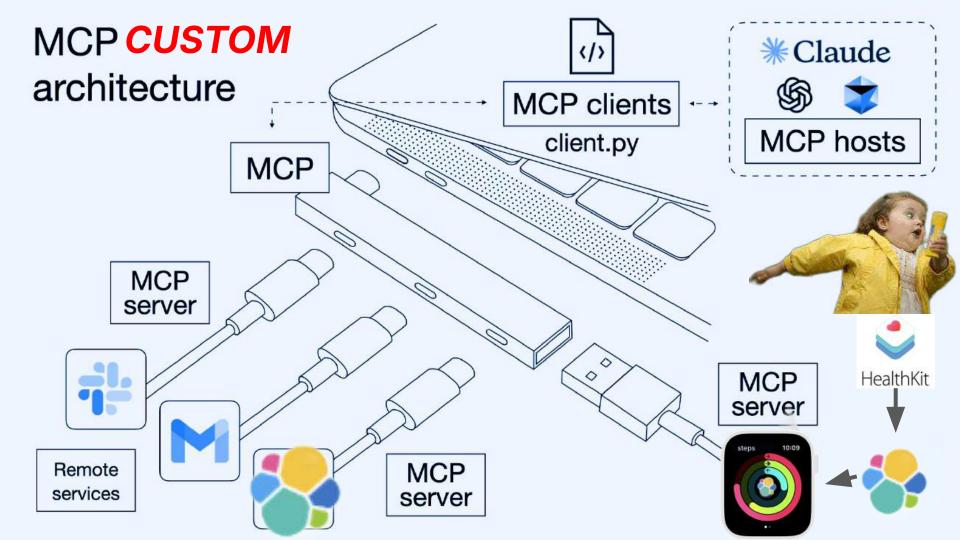
- Busca → Retrieve → Generate
- Pipeline fixo
- Uma fonte por vez
- Sem raciocínio

RAG Agêntico com MCP

- Planeja → Executa → Valida → Itera
- Adaptativo
- Multi-fonte simultâneo
- Raciocínio complexo

O LLM decide quando, onde e como buscar





Como começar?

```
# Create project and install dependencies
uv init apple-watch-mcp
cd apple-watch-mcp
uv venv
source .venv/bin
uv add "mcp[cli]" elasticsearch httpx pydantic
```

Configuração simples com ferramentas Python comuns

A CLI do MCP fornece ferramentas de desenvolvimento

Apenas algumas dependências necessárias



Os dados de exemplo

```
devtools

{
    "type": "HKQuantityTypeIdentifierStepCount",
    "sourceName": "Apple Watch",
    "startDate": "2025-05-01 07:58:42",
    "endDate": "2025-05-01 07:59:10",
    "value": 34,
    "day": "2025-05-01",
    "dayOfWeek": "Thursday",
    "hour": 7
}
```

Dados de fitness de série temporal no Elasticsearch

Múltiplos dispositivos rastreando as mesmas métricas

Perfeito para demonstrar capacidades de busca



< apple_health_export		02B A	ф <i>О</i>	⊕
Name	Clare Modified			Kind
electrocardiograms	2 May 2025 at 00:02			Folder
ecg_2024-05-12.esv				
ecg_2024-05-29.csv	1 May 2025 at 13-36		116 KB	
ecg_2024-06-11.csv	1 May 2025 at 13:36			
ecg_2024-07-16.csv	1 May 2025 at 13:36		117 KB	CSV Document
ecg_2024-08-25.csv	1 May 2025 at 13:36			
ecg_2024-09-04_1.csv				
ecg_2024-09-04.csv	1 May 2025 at 13:36			
export_oda.xml	1 May 2025 at 13:36		90,5 MB	XML Document
m export.xmi	1 May 2025 at 13:36		246,3 MB	XML Document
workout-routes	2 May 2025 at 00-02			Folder
route_2024-96-15_10.13am.gpx	1 May 2025 at 13:36			
route_2024-06-20_9.21am.gpx				GPX File
route_2024-07-14_12.07pm.gpx				GPX File
route_2024-06-27_12.32pm.gpx				GPX Fig.
route_2024-09-04_4.51pm.gpx			2 KE	-GPX File
noute_2024-10-05_9.01am.gpx	1 May 2025 at 12-50	-	246 KB	
noute_2024-10-29_3.43pm.gpx	1 May 2025 at 13:36		666 bytes	
mule 2024-10-29 5 04pm any	3 May 2026 of 39 SR		18 88	CDV Elle



Inicialização do servidor

```
...
                          apple_watch_mcp.pv
# Step 1: Import the FastMCP framework
from mcp.server.fastmcp import FastMCP
import httpx
# Step 2: Create your MCP server instance
# FastMCP handles protocol details so you focus on implementation
mcp = FastMCP("apple-watch-steps")
# Step 3: Define your Elasticsearch connection params
ES_HOST = "http://localhost:9201"
ES_INDEX = "apple-health-steps"
# Step 4: Create a helper function for Elasticsearch queries
# This centralizes your query logic and error handling
async def query_elasticsearch(query: dict):
    async with httpx.AsyncClient() as client:
        response = await client.post(
            f"{ES_HOST}/{ES_INDEX}/_search", json=query
        return response.json()
```





MCP: Os Três Primitivos Fundamentais



Resources

Data Access
Provide context to LLM
Like GET endpoints



Tools

Actions & Computation
Execute operations
Like POST endpoints



Prompts

Interaction Templates Guide conversations Like workflow recipes

juntos, essas primitivas formam um sistema completo para conectar LLMs a funcionalidades externas



Resources: Os Olhos do LLM

```
000
                     apple_watch_mcp.py
@mcp.resource("health://steps/latest")
async def get_latest_steps() -> str:
    """Get latest step counts"""
    # URI pattern choice: namespaced by domain
    # Return format: Always JSON strings for consistency
    # Query design: Simple, focused on single concern
    query = {
        "query": {"match_all": {}},
        "sort": [{"endDate": {"order": "desc"}}],
        "size": 10
    data = await query_elasticsearch(query)
    # Process and return formatted results...
```

- URI Pattern: "health://steps/latest"
- Purpose: Retrieves data without modification
- Acts like: Read-only GET endpoints



Tools: As Mãos do LLM

```
000
                    apple_watch_mcp.py
(dmcp.tool()
async def query_step_data(params: QueryParams) -> str:
    """Query step data with parameters"""
    # Extract parameters
    start_date = params.start_date
    end_date = params.end_date
    aggregation = params aggregation
    # Build Elasticsearch query
    query = {"query": {"match_all": {}}}
    filters = []
    # Add date filters if specified
    if start_date or end_date:
        date_filter = {"range": {"day": {}}}
        if start_date:
```

- Accepts Parameters:
 Structured input objects
- **Dynamic Logic:** Varies based on parameters
- Active Processing: Not just data retrieval

Tools enable action and computation — essential for complex queries and analysis



Prompts: Os Mapas para o LLM

```
000
                   apple_watch_mcp.py
(amcp.prompt()
def daily_report(date: str = None) -> str:
    """Daily step analysis report"""
    if date:
        return f"""Analyze my step data for {date}.
Please include:
1. Total steps taken
2. Most active periods
3. Device breakdown
4. Compare to my weekly average
5. Visualize my activity pattern""
    else:
        return """Analyze today's step data..."""
```

- Appears as: / commands in Claude
- Provides Structure: For common tasks
- **User-Triggered:** Start specific workflows

Prompts criam experiências consistentes para padrões de análise frequentes.



Validação de Tipo - Crítico para Confiabilidade

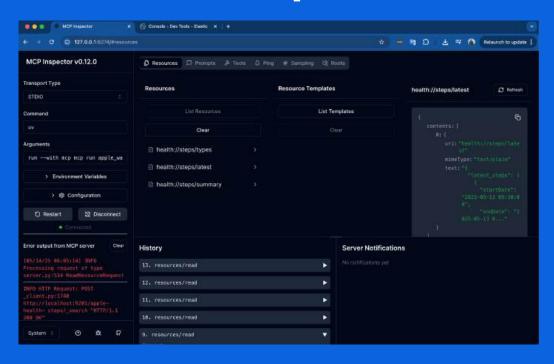
```
000
                           apple_watch_mcp.py
# Pydantic model for parameter validation
class QueryStepDataParams(BaseModel):
    start_date: Optional[str] = None
    end_date: Optional[str] = None
    aggregation: Optional[str] = None
    device: Optional[str] = None
    @field_validator('start_date', 'end_date')
    def validate_date_format(cls, value):
        if value is None:
            return value
        try:
            datetime.strptime(value, "%Y-%m-%d")
            return value
        except ValueError:
            raise ValueError("Invalid date format. Use YYYY-MM-DD")
```

Why Pydantic?

- 1. Runtime **validation** with clear error messages
- 2. Self-documenting code
- 3. **Seamless** FastMCP integration



Testando com o MCP Inspector



For Developers

Test resources and tools interactivelyView raw JSON responses from Elasticsearch

Key Features

- Real-time API testing
- Request history tracking

Integration

- Shows live Elasticsearch queries
- •Helps debug before deploying to Claude



Deployment & Integration

mcp install apple_watch_mcp.py



```
...
           claude_desktop_config.json
  "mcpServers": {
    "Apple Health Steps": {
      "command":
"/Users/alexsalgado/.local/bin/uv",
      "args": [
        "--directory",
"/Users/alexsalgado/Desktop/blog-mcp-
server/new-blog/apple-watch-mcp",
        "run",
        "apple_watch_mcp.py"
```



Demo: A Mágica Acontecendo

Busca 2.0 (Tradicional)

```
GET /health_metrics/_search
  "query": {
    "bool": {
      "must": [
        { "range": {
          "timestamp": {
            "gte": "now-30d"
          "match": { "user id": "user123" }}
    "daily_steps": {
      "date histogram": {
        "field": "timestamp",
        "interval": "day"
        "avg_steps": {
          "avg": { "field": "metrics.steps" }
```

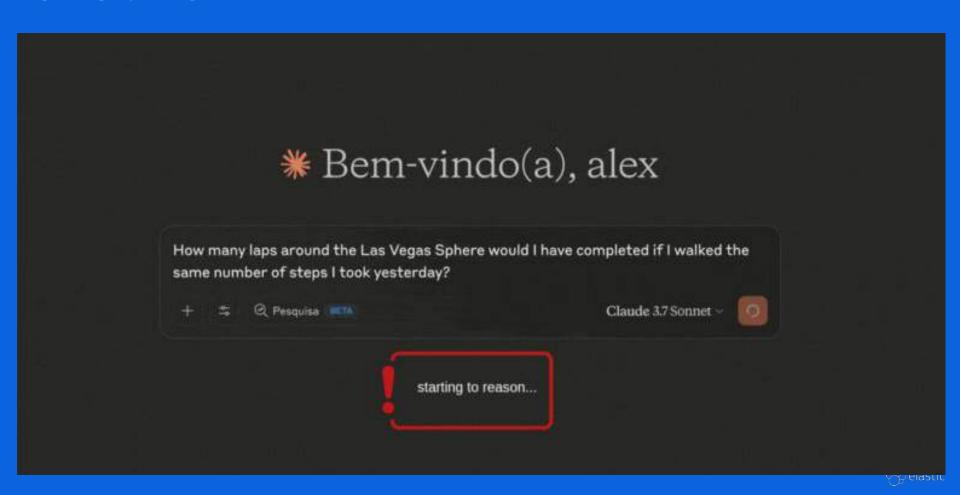
Busca 3.0 (Com MCP)

"Como foram meus passos este mês?"

O LLM:

- 1. Entende a pergunta
- 2. Chama search_health_data()
- 3. Processa resultados
- 4. Gera resposta natural

Demo time



Casos de Uso Prático com MCP Customizado



Análise de Logs

"Por que o sistema caiu ontem às 15h?"

MCP conecta aos logs de aplicação, servidores e infraestrutura para identificar padrões e causas raiz automaticamente.



Business Intelligence

"Qual produto tem melhor margem no Q3?"

Integra dados de vendas, custos e inventário para análises complexas sem necessidade de SQL ou dashboards.



DevOps & Monitoramento

"Qual serviço está consumindo mais recursos?"

Conecta métricas de Prometheus, CloudWatch ou Datadog para insights operacionais em tempo real.



Gestão de Documentos

"Quais contratos vencem este mês?"

Analisa PDFs, contratos e documentos legais extraindo informações críticas automaticamente.



Segurança & Compliance

"Houve tentativas de acesso suspeitas?"

Monitora logs de segurança, detecta anomalias e garante conformidade com políticas internas.



Integração de Sistemas

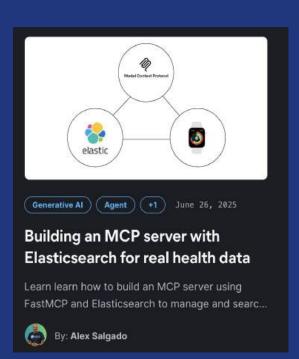
"Sincronize dados entre CRM e ERP"

Orquestra fluxos de dados entre sistemas legados e modernos sem código adicional.





Recursos para desenvolvedores: Elasticsearch Labs







youtube.com/@OfficialElasticCommunity

elastic.co/search-labs

github.com/elastic/elasticsearch-labs



Recursos para desenvolvedores: Junte-se à Comunidade Elastic

Elastic User Groups

Estamos sempre em busca de organizadores, palestrantes e participantes.
Encontre mais eventos Elastic em todo o mundo em community.elastic.co



elastic.co/community









Meetups







ELASTIC

@alexsalgadoprof

POR TEMPO LIMITADO



Não se trata de **se** você vai usar, mas **quando**. E, nessa jornada, cada **passo** importa.

Apenas comece.

Obrigado







